

IoT SNAPSHOT DOCUMENTS: HYBRID RAG NHẬN BIẾT THỜI GIAN THỰC CHO TRỢ LÝ HỎI-ĐÁP BÃI ĐỒ XE THÔNG MINH

Trần Văn Còn¹, Phan Anh Cang¹

¹ Trường Đại học Sư phạm Kỹ thuật Vĩnh Long

22004015@st.vlute.edu.vn

TÓM TẮT — Trợ lý hội thoại dựa trên mô hình ngôn ngữ lớn (LLM) cho không gian vật lý thông minh phải trả lời cả câu hỏi tri thức tĩnh lẫn câu hỏi trạng thái thời gian thực. Bài báo đề xuất IoT Snapshot Documents: vật chất hóa định kỳ trạng thái thiết bị IoT thành tài liệu ngôn ngữ tự nhiên có TTL, nhúng vào cùng chỉ mục truy hồi với tài liệu tĩnh, hợp nhất trong một câu SQL lai (BM25 + pgvector + RRF $k=60$) với lọc độ-cũ tại tầng truy hồi. Hệ thống hiện thực end-to-end trên bãi đỗ AIoT thực (ESP32-C3 + UWB → MQTT → máy chủ biên NestJS → di động). Kết quả đo trên 101 câu (40 tri thức tĩnh + 61 trạng thái-IoT): RAG nâng độ chính xác từ 5,0% (closed-book) lên 86,1% (Hybrid RAG, +81,1 điểm phần trăm); nhóm trạng thái-IoT: 1,6% → 82,0%; lọc TTL vượt snapshot cũ +6,6 điểm phần trăm. Bài báo công bố mã nguồn và harness đánh giá tái lập.

Từ khóa — UWB; định vị trong nhà; AIoT; Retrieval-Augmented Generation; hybrid retrieval; Reciprocal Rank Fusion; pgvector; bãi đỗ xe thông minh; trợ lý hội thoại

Trợ lý hội thoại dựa trên mô hình ngôn ngữ lớn (LLM) cho không gian vật lý thông minh phải trả lời cả câu hỏi *tri thức tĩnh* (quy định, hướng dẫn) lẫn câu hỏi *trạng thái thời gian thực* ("xe 51A ở đâu", "tầng 2 còn chỗ không"). Sinh-tăng-cường-truy-hồi (RAG) kinh điển [8] giả định kho tài liệu *tĩnh*, không phù hợp dữ liệu cảm biến biến đổi liên tục; còn cách gọi-công-cụ (tool-calling) lại phụ thuộc việc LLM chọn đúng công cụ. Bài báo đề xuất **IoT Snapshot Documents**: vật chất hóa định kỳ trạng thái thiết bị IoT thành tài liệu ngôn ngữ tự nhiên có dấu thời gian và thời gian sống (TTL), nhúng vào *cùng chỉ mục truy hồi* với tài liệu tĩnh, hợp nhất trong *một câu truy vấn SQL lai* (BM25 [6] song song tìm kiếm vector pgvector, hòa trộn bằng Reciprocal Rank Fusion RRF, $k=60$ [7]), với *lọc độ-cũ* đặt ngay tại tầng truy hồi (*snapshot_ts > NOW() - INTERVAL '2 hours'*) để chặn ngữ cảnh lỗi thời ngay từ cấu trúc truy vấn, không can thiệp LLM. Hệ thống hiện thực end-to-end trên bãi đỗ AIoT thực (ESP32-C3 + UWB → MQTT [15] → máy chủ biên NestJS → di động). **Kết quả đo:** trên bộ **101 câu** (40 tri thức tĩnh + 61 trạng thái-IoT, đáp án vàng chốt từ CSDL tại thời điểm hỏi), RAG nâng độ chính xác câu trả lời từ **5,0%** (closed-book) lên **86,1%** (open-book Hybrid RAG, +81,1 điểm phần trăm; câu có số chấm khách quan bằng Exact/Numeric Match đạt 100%), riêng nhóm trạng thái-IoT thay đổi nhanh tăng **1,6% → 82,0%**; lọc TTL giữ snapshot tươi vượt snapshot cũ **+6,6 điểm phần trăm** (faithfulness 0,997). Về truy hồi, **chất lượng do nhánh ngữ nghĩa (vector) quyết định** (Recall@5 = 0,821, MRR = 0,962); BM25 đóng vai trò ***lưới an toàn*** cho truy vấn chứa mã định danh chính xác, và RRF ***bảo toàn*** chất lượng nhánh vector trong khi hợp nhất hai tín hiệu. Đóng góp hệ thống nằm ở việc hợp nhất truy hồi lai trong ***một câu SQL duy nhất*** (tận dụng bộ tối ưu CSDL thay vì điều phối ở tầng ứng dụng) và ở cơ chế ***trạng-thái-thành-tài-liệu-có-TTL*** cùng chỉ mục*. Bài báo công bố mã nguồn và harness đánh giá tái lập;

Từ khóa — Retrieval-Augmented Generation; hybrid retrieval; Reciprocal Rank Fusion; pgvector; IoT; bãi đỗ xe thông minh; UWB; trợ lý hội thoại.

I. GIỚI THIỆU

Hệ thống bãi đỗ xe thông minh dựa trên AIoT đang trở thành thành phần cốt lõi của hạ tầng giao thông đô thị, với khả năng giám sát thời gian thực vị trí xe, mức lấp đầy từng tầng và trạng thái thiết bị [13][14]. Khi tích hợp một trợ lý hội thoại dựa trên LLM lên trên hạ tầng đó, người dùng kỳ vọng đặt câu hỏi bằng ngôn ngữ tự nhiên về cả tri thức vận hành (ví dụ quy định ra vào, cách tìm xe) lẫn trạng thái hiện thời của không gian vật lý.

Tuy nhiên, hai khoảng trống kỹ thuật nổi lên. **Thứ nhất**, RAG kinh điển [8] và truy hồi đặc (dense retrieval) [9] được thiết kế cho một kho ngữ liệu *tĩnh*: tài liệu được nhúng (embed) một lần và phục vụ lâu dài. Telemetry IoT — vốn thay đổi từng giây — không khớp với giả định này; việc nhúng lại toàn bộ trạng thái liên tục là bất khả thi về chi phí, còn để dữ liệu cũ trong chỉ mục thì gây "ngữ cảnh ôi" (stale context). **Thứ hai**, kiến trúc gọi-công-cụ — trong đó LLM chọn một API/tool cho mỗi loại câu hỏi — đẩy gánh nặng định tuyến sang LLM: với câu hỏi mơ hồ hoặc đa-mục-đích, LLM có thể chọn sai công cụ, và mỗi loại trạng thái mới lại đòi một tool riêng.

Bài báo đặt câu hỏi nghiên cứu: *Làm thế nào để một trợ lý hội thoại trả lời thống nhất cả câu hỏi tri thức tĩnh lẫn câu hỏi trạng thái thời gian thực, mà không phụ thuộc vào việc LLM chọn đúng công cụ và không để ngữ cảnh lỗi thời rò rỉ vào câu trả lời?*

Bài báo có bốn đóng góp:

- IoT Snapshot Documents** — một mẫu kiến trúc biến trạng thái IoT động (trạng thái thiết bị, mức lấp đầy tầng, vị trí xe + độ chính xác) thành tài liệu ngôn ngữ tự nhiên có snapshot_ts, vật chất hóa định kỳ và lưu **cùng bảng, cùng chỉ mục** với tài liệu tĩnh, qua đó biến *truy vấn trạng thái vật lý* thành *truy hồi tài liệu ngữ nghĩa*. Khác với search-engine-augmentation/realtime-RAG [16][17] (truy hồi từ web/nhúng lại liên tục) và cache-augmented generation (nạp toàn bộ ngữ cảnh vào prompt), chúng tôi giữ một chỉ mục thống nhất và chỉ vật chất hóa định kỳ những lát trạng thái cô đọng.
- Lọc độ-cũ tại tầng truy hồi (an toàn theo cấu trúc)** — thay vì để LLM tự phán đoán độ tươi, điều kiện TTL

(`snapshot_ts > NOW() - INTERVAL '2 hours'`) được đẩy thẳng vào câu truy vấn. Đây trước hết là một bảo đảm *theo cấu trúc* (by construction): ngữ cảnh quá hạn không bao giờ lọt vào prompt, bất kể trạng thái tích lũy theo thời gian. Bảo đảm cấu trúc này được hỗ trợ bằng bằng chứng *answer-level* (+6,6 điểm phần trăm khi giữ snapshot tươi so với để snapshot cũ, §IV-D). 3. **Hợp nhất truy hồi lại trong một câu SQL** — BM25 [6] song song tìm kiếm vector cosine (pgvector), hòa trộn bằng RRF [7] ($k=60$) qua một FULL OUTER JOIN duy nhất. Đóng góp ở đây *không* phải tuyên bố hybrid chính xác hơn vector (trên bộ nhân của chúng tôi, hai cấu hình cho chất lượng ngang nhau — §IV-B), mà là (i) hợp nhất hai nhánh trong **một vòng truy vấn duy nhất**, tận dụng bộ tối ưu/lập kế hoạch truy vấn của CSDL thay vì điều phối nhiều tầng ở ứng dụng, và (ii) bổ sung tính bền vững (robustness) cho truy vấn khớp-chính-xác (exact-match) nhờ nhánh BM25, trong khi RRF bảo toàn chất lượng nhánh vector. 4. **Hiện thực end-to-end và đánh giá tái lập** — kiến trúc AIoT đầu-cuối (firmware ESP32-C3 → MQTT → máy chủ biên → di động) cùng mã nguồn và harness đánh giá truy hồi/chatbot/định vị, công bố minh bạch dữ liệu nào đã đo và dữ liệu nào còn synthetic.

Khác với IoT-LLM [11], ChatIoT [10] và RAG-IoE [12] — vốn lần lượt nhét dữ liệu cảm biến vào prompt/chuỗi suy luận, làm RAG trên kho tĩnh về IoT, hoặc truy hồi nhận-biết-ngữ-cảnh — đề xuất của chúng tôi để *trạng thái-thành-tài-liệu* nằm cùng chỉ mục với tài liệu tĩnh, hòa trộn trong một câu truy vấn lai duy nhất, và xử lý staleness tường minh ngay khi truy hồi.

II. CÔNG TRÌNH LIÊN QUAN

A. Định vị UWB trong nhà và bãi đỗ xe

Công nghệ Ultra-Wideband (UWB) cung cấp định vị trong nhà độ chính xác mức xen-ti-mét trong điều kiện tầm-nhìn-thẳng (LOS), nhờ băng thông xung lớn và kỹ thuật đo khoảng cách thời gian-bay (time-of-flight) chuẩn hóa trong IEEE 802.15.4z [1]. Khảo sát toàn diện về UWB định vị thời gian thực trong nhà [3] tổng hợp các kiến trúc anchor-tag, thuật toán đa-giác-cạnh (trilateration/multilateration) và nguồn sai số. Hạn chế chính của UWB là suy giảm độ chính xác trong điều kiện không-tầm-nhìn-thẳng (NLOS), nơi sai số có thể tăng lên mức mét; các công trình [4][5] đề xuất nhận dạng và giảm thiểu sai số NLOS dựa trên đặc trưng đáp ứng xung kênh (CIR). Trong hệ thống của chúng tôi, UWB chỉ đóng vai trò *nguồn dữ liệu trạng thái*; đóng góp khoa học không nằm ở thuật toán định vị, và các con số độ chính xác trích từ [3][4][5] được dùng để biện luận lựa chọn công nghệ, **không** tuyên bố là kết quả của nghiên cứu này.

B. Lọc nhiễu quỹ đạo định vị

Để làm mượt quỹ đạo nhiễu, bộ lọc Kalman/EKF là lựa chọn phổ biến nhưng đòi hỏi mô hình động học và ma trận hiệp phương sai, đồng thời các công trình giảm sai số NLOS [4][5] thường gắn với pipeline phức tạp. Bài báo dùng **1€ Filter** (One-Euro) [2] — bộ lọc thông thấp thích nghi theo tốc độ, gốc từ lĩnh vực Tương tác Người–Máy — chỉ với hai tham số (minCutoff, beta), không cần mô hình động học. Áp dụng One-Euro để làm mượt quỹ đạo UWB phía máy chủ biên là một góc tích hợp ít gặp; đây là **đóng góp kỹ thuật phụ**, không phải thuật toán lọc mới.

C. RAG và truy hồi lai

RAG [8] tăng cường LLM bằng các đoạn văn bản truy hồi từ kho ngoài; truy hồi đặc DPR [9] dùng biểu diễn vector học sẵn. BM25 [6] là chuẩn truy hồi thưa (sparse) dựa trên thống kê từ khóa. Truy hồi lai kết hợp tín hiệu thưa và đặc; Reciprocal Rank Fusion [7] hòa trộn nhiều bảng xếp hạng chỉ dựa trên thứ hạng (rank), với hằng số k điều tiết ảnh hưởng của các vị trí thấp. Hệ thống của chúng tôi **tái sử dụng trực tiếp** các kỹ thuật này (BM25 + pgvector + RRF $k=60$); đóng góp **không** nằm ở bản thân thuật toán hòa trộn, mà ở *đối tượng được đưa vào chỉ mục* (snapshot IoT) và *cơ chế lọc độ-cũ tại tầng truy hồi*.

D. RAG nhận biết IoT và LLM cho IoT

Đây là nhóm gần nhất với đóng góp của bài. Ở phía hỏi-đáp thay-đổi-nhanh, RealTime QA [17] và FreshLLMs [16] cho thấy LLM trả lời sai câu trạng thái hiện thời nếu không được tăng cường thông tin tươi, và đề xuất tăng cường bằng tìm-kiểm-web — những nguồn tươi của họ là web công cộng, không phải telemetry cảm biến của chính hệ thống. Ở phía IoT, IoT-LLM [11] tăng cường suy luận của LLM từ dữ liệu cảm biến thực bằng cách đưa dữ liệu vào ngữ cảnh/chuỗi suy luận. ChatIoT [10] là trợ lý an ninh IoT dùng RAG trên kho tài liệu (tĩnh) về bảo mật IoT. RAG-IoE [12] thực hiện truy hồi thông tin nhận-biết-ngữ-cảnh-IoT cho Industry 5.0. **Khác biệt cốt lõi** của đề xuất chúng tôi: trạng thái thời gian thực được *vật chất hóa thành tài liệu có TTL nằm cùng chỉ mục* với tài liệu tĩnh, hòa trộn trong **một câu SQL lai duy nhất**, và staleness được lọc ngay ở **tầng truy hồi** — không nhét trạng thái vào prompt, không dùng kho tĩnh, và không phụ thuộc LLM định tuyến tool. Bảng dưới đối chiếu định tính các đặc trưng kiến trúc này.

Bảng so sánh đặc trưng (định tính) với các hướng liên quan.

Hướng tiếp cận
ChatIoT [10]
IoT-LLM [11]

Hướng tiếp cận
RAG-IoE [12]
FreshLLMs [16]
RealTime QA [17]
Đề xuất

E. Bãi đỗ xe thông minh IoT

Các khảo sát về quản lý bãi đỗ thông minh dựa trên IoT [13] và cảm biến/công nghệ cho bãi đỗ mở [14] cung cấp bối cảnh ứng dụng: giám sát chỗ trống, dẫn đường, và tích hợp đa cảm biến. Đề xuất của chúng tôi bổ sung một lớp *truy vấn hội thoại* lên trên hạ tầng giám sát đó.

III. PHƯƠNG PHÁP ĐỀ XUẤT

A. Tổng quan kiến trúc AIoT

Hệ thống gồm bốn tầng (Hình 1). Tầng *thiết bị* dùng mô-đun ESP32-C3 ghép UWB EWT550: các anchor cố định AA01–AA04 và tag gắn xe AB00 thực hiện đo khoảng cách. Tầng *truyền tin* dùng MQTT [15]: tag công bố một bản tin chứa khoảng cách tới toàn bộ anchor mỗi giây tới topic `iot/{chip_id}/uwb`. Tầng *máy chủ biên* (NestJS) thực hiện trilateration bình-phương-tối-thiểu tuyến-tính-hóa (stateless theo từng gói, ≥ 3 anchor), làm mượt quỹ đạo bằng One-Euro Filter ($\text{minCutoff}=0.5$ Hz, $\text{beta}=0.1$, $\text{dCutoff}=1$ Hz), và đẩy vị trí qua Server-Sent Events. Tầng *ứng dụng* hiển thị bản đồ và phục vụ trợ lý hội thoại. Trợ lý chính là đối tượng nghiên cứu của bài: nó cần truy cập cả tri thức tĩnh và trạng thái thời gian thực của ba tầng dưới.

B. IoT Snapshot Documents

Ý tưởng trung tâm: thay vì viết một API/tool riêng cho mỗi loại câu hỏi trạng thái, máy chủ *vật chất hóa định kỳ* trạng thái IoT thành tài liệu ngôn ngữ tự nhiên rồi đưa vào cùng chỉ mục truy hồi với tài liệu tĩnh (Hình 2).

Một tiến trình nền (IoTSnapshotService) chạy mỗi 5 phút (288 lần/ngày, dưới hạn ngạch nhúng) sinh ba loại snapshot: - **Trạng thái thiết bị** (`source_type='device'`): danh sách thiết bị online/offline, lấy từ tập Redis `iot:online_devices`. Nếu có thiết bị offline, sinh thêm một tài liệu loại `alert`. - **Mức lấp đầy tầng** (`source_type='occupancy'`): với mỗi tầng đã khảo sát (có kích thước vật lý), đếm số xe hoạt động trong cửa sổ 5 phút từ bảng `vehicle_history`. - **Vị trí xe** (`source_type='vehicle-pos'`): vị trí gần nhất của mỗi xe trong 60 giây qua, kèm độ chính xác (mét) và trạng thái ("đang di chuyển" nếu mới <30 giây, ngược lại "đỗ").

Mỗi snapshot là một văn bản ngắn tiếng Việt mở đầu bằng nhãn `[SNAPSHOT <giờ>]`, ví dụ: `"[SNAPSHOT 14:32:05] Vị trí xe — Xe AB00 ở tầng F1, toạ độ (3.20m, 5.10m). Độ chính xác: 0.12m. Trạng thái: đỗ."` Văn bản được nhúng và INSERT vào bảng `knowledge_chunks` với `chunk_type='iot_snapshot'`, kèm `snapshot_ts`, `floor_id`, `source_type`. Tài liệu tĩnh (mô tả hệ thống, quy định) nằm trong cùng bảng với `chunk_type='static'`. Như vậy hai loại tri thức **chia sẻ một không gian truy hồi duy nhất**.

C. Lọc độ-cũ (TTL) tại hai tầng

Độ-cũ được khống chế ở hai nơi. Tại **tầng truy hồi**, truy vấn lai chỉ chấp nhận chunk thỏa `chunk_type = 'static' OR snapshot_ts > NOW() - INTERVAL '2 hours'`: tài liệu tĩnh luôn hợp lệ, snapshot quá hạn 2 giờ bị loại ngay khi tìm kiếm. Tại **tầng lưu trữ**, một tiến trình dọn dẹp (mỗi 10 phút) DELETE snapshot thường cũ hơn 2 giờ và snapshot loại `alert` cũ hơn 24 giờ — cảnh báo được giữ lâu hơn để truy vết sự cố. Cơ chế hai tầng đảm bảo: kể cả khi tiến trình dọn dẹp trễ, truy vấn vẫn không trả về ngữ cảnh lỗi thời.

D. Tìm kiếm lai trong một câu SQL

Hàm `hybridSearch(query, limit)` thực thi **một** câu SQL gồm các Common Table Expression:

1. `vector_ranked` — xếp hạng theo khoảng cách cosine `pgvector` (`embedding <=> $query_vec`, 768 chiều), lọc theo điều kiện độ-cũ, lấy 20 ứng viên. 2. `bm25_ranked` — xếp hạng theo `ts_rank(search_vector, plainto_tsquery('simple', $query))`, cùng điều kiện độ-cũ, lấy 20 ứng viên. 3. `fused` — FULL OUTER JOIN hai bảng theo id, tính điểm RRF:

$score(d) = 1/(k + rank_vec(d)) + 1/(k + rank_bm25(d))$, với $k = 60$; tài liệu vắng mặt ở một nhánh được gán hạng mặc định 20 (qua COALESCE).

4. Kết quả nối lại bảng gốc, sắp theo `rrf_score` giảm dần, trả về `limit` (chặn trong [1, 20]) chunk.

Việc đặt mọi thứ trong một câu SQL cho phép cơ sở dữ liệu tối ưu hai nhánh tìm kiếm và hòa trộn trong một vòng truy vấn duy nhất, không cần điều phối ở tầng ứng dụng.

E. Tích hợp trợ lý hội thoại

Kết quả hybridSearch được công cụ search_knowledge (MCP) trả về cho LLM trong vòng lặp agentic. Vì snapshot mới nhất luôn nằm trong cửa sổ TTL và xếp hạng cao theo cả từ khóa lẫn ngữ nghĩa, câu hỏi trạng thái mơ hồ vẫn truy hồi đúng tài liệu trạng thái hiện thời mà không cần LLM chọn tool chuyên biệt.

IV. HIỆN THỰC VÀ ĐÁNH GIÁ

Để tăng tính tái lập và giúp người đọc nắm thiết lập, Bảng I tổng hợp cấu hình của toàn bộ thí nghiệm (chỉ tổ chức lại thông tin đã rải rác trong bài, không bổ sung số liệu mới). Định nghĩa **faithfulness** (theo RAGAS [18]) được dùng nhất quán: tỉ lệ mệnh đề (claim) trong câu trả lời được *ngữ cảnh truy hồi hỗ trợ* trên tổng số mệnh đề — một thước đo chống-bịa không cần đáp án vàng.

Bảng I — Cấu hình thực nghiệm tổng hợp.

Thí nghiệm	
Truy hồi (§IV-B)	
Lọc TTL (§IV-C)	
Chatbot trước/sau RAG (§IV-D)	
Ba môi trường (§IV-D)	
Độ trễ truy hồi (§IV-E)	
Định vị UWB (§IV-E)	

A. Hiện thực

Máy chủ biên hiện thực bằng NestJS/TypeScript, PostgreSQL với phần mở rộng pgvector cho vector 768 chiều và tsvector/ts_rank cho BM25. Nhúng dùng mô hình gemini-embedding-001 (768 chiều). Khi không có khóa API hợp lệ, hàm embed() trả về *vector-không* (zero-vector) để hệ thống tiếp tục hoạt động chỉ với BM25 — đây là một giới hạn cấu hình (xem §IV-G).

B. Giao thức đánh giá truy hồi

Để đánh giá đóng góp chính, chúng tôi đề xuất một bộ ~30–50 cặp câu hỏi–đáp **không-thời-gian** (truy vấn trạng thái như "tầng 2 còn chỗ không", "thiết bị nào offline", "xe 51A ở đâu") được sinh **có kiểm soát** và gán nhãn tài liệu liên quan; bộ này được công bố minh bạch là **synthetic** (sinh từ trạng thái hệ thống mô phỏng, không phải log người dùng thật). Các chỉ số: **Recall@k**, **nDCG@k**, **MRR** cho chất lượng truy hồi, và **độ chính xác câu trả lời** (answer correctness) cho đầu-ra cuối. Harness đánh giá truy hồi (apps/iot-server/scripts/eval-retrieval.ts) nạp bộ QA, gọi đúng hybridSearch() thật và tính các chỉ số trên. Lần chạy báo cáo dưới đây dùng **13 câu hỏi gán nhãn thủ công** trên corpus 135 chunk (15 tài liệu tĩnh + 120 snapshot IoT), với embedding sinh **cục bộ bằng `embeddinggemma`** (Ollama, 768 chiều, không dùng API đám mây).

Bảng II — Kết quả truy hồi (synthetic QA).

Cấu hình	
Hybrid (BM25 + vector + RRF)	
Chỉ vector	
Chỉ BM25	

Trên bộ 13 câu hỏi gán nhãn, truy hồi ngữ nghĩa quyết định độ chính xác: Recall@5 đạt 0,821 (MRR 0,962) so với chỉ 0,026 của BM25 thuần, cho thấy khớp từ khóa đơn thuần không đủ cho truy vấn ngôn ngữ tự nhiên tiếng Việt. Đáng lưu ý, Hybrid RRF **đạt cùng** Recall/nDCG/MRR với cấu hình chỉ-vector trên bộ câu hỏi này: RRF *bảo toàn* chất lượng của nhánh vector đồng thời bổ sung BM25 như một *lưới an toàn* cho các truy vấn chứa mã định danh chính xác (ví dụ "AA01"). Vì hai cấu hình ngang nhau trên bộ nhân nhỏ này, chúng tôi **không** tuyên bố hybrid vượt vector về chất lượng; việc định lượng lợi ích riêng của BM25/RRF cần một bộ nhân lớn hơn với nhiều truy vấn khớp-chính-xác (xem mục Giới hạn). Hit@5 = 1,000 (mọi câu đều có ít nhất một đoạn liên quan trong top-5); Precision@5 = 0,338 phản ánh mỗi câu chỉ có khoảng 1–2 đoạn liên quan nên trần lý thuyết của Precision@5 cũng quanh mức 0,34 — tức truy hồi đạt gần trần Precision@5 trên bộ nhân nhỏ này; MAP = 0,727.

C. Nghiên cứu cắt bỏ (ablation)

Ba trục cắt bỏ, tất cả chạy offline trên bộ QA synthetic:

1. **Hợp nhất**: hybrid vs chỉ-vector vs chỉ-BM25 (Bảng II) — đối chiếu các nhánh truy hồi. 2. **Lọc độ-cũ**: có vs không điều kiện snapshot_ts > NOW() - INTERVAL '2h' — đo ảnh hưởng tới chất lượng và độ trễ truy hồi. 3. **Hằng số k của RRF**: quét k ∈ {10, 30, 60, 100} — kiểm chứng lựa chọn k=60.

Bảng III — Lọc TTL tại tầng truy hồi: chi phí latency (chất lượng trung tính trên corpus hiện tại).

Cấu hình
Có TTL (2h)
Không TTL

Cần phân định **hai loại bằng chứng** về TTL. (1) *Bằng chứng tầng truy hồi* (Bảng III): trên corpus hiện tại (snapshot vừa sinh, chưa có dữ liệu quá hạn), bật/tắt TTL cho chỉ số chất lượng **giống hệt nhau** — nên Bảng III chủ yếu phản ánh **chi phí latency** của bộ lọc (p95 tăng 297 ms → 1185 ms do thêm điều kiện thời gian vào cả hai nhánh). Lợi ích chất lượng của TTL ở tầng này mang tính *cấu trúc* (an-toàn-theo-cấu-trúc: chặn ngữ cảnh lỗi thời khi snapshot tích lũy theo thời gian thực) và cần một corpus có snapshot quá hạn để định lượng tỉ lệ ngữ cảnh lỗi thời — đây là hướng đánh giá tiếp theo. (2) *Bằng chứng answer-level* xuất hiện ở §IV-D (+6,6 điểm phần trăm khi cố ý giữ snapshot tươi so với để snapshot cũ); đó mới là phép đo trực tiếp ảnh hưởng của staleness lên câu trả lời. Quan sát định tính: ở hai câu hỏi (về anchor và thiết bị offline), các snapshot cảnh báo chen vào hạng 2–5, gợi ý snapshot IoT thực sự tham gia cạnh tranh xếp hạng.

D. Đánh giá chatbot end-to-end: trước/sau RAG

Để đo trực tiếp đóng góp của IoT Snapshot Documents lên *câu trả lời cuối* (không chỉ truy hồi), chúng tôi so sánh hai cấu hình sinh trên cùng bộ câu hỏi và cùng mô hình: **closed-book** (LLM chỉ dùng tri thức tham số — không ngữ cảnh, không công cụ) và **open-book Hybrid RAG** (chèn top-5 đoạn truy hồi, gồm cả IoT snapshot). Hai cấu hình cố ý đều **không dùng tool-calling** để cô lập đúng tác động của truy hồi. Bộ đánh giá gồm **101 câu**: 40 câu *tri thức tĩnh* (G1) và 61 câu *trạng thái-IoT thay đổi nhanh* (G2 — đáp án vàng chốt từ CSDL/Redis tại thời điểm hỏi). Mô hình sinh và chấm là deepseek-chat (temperature 0); embedding embeddinggemma (768 chiều) dùng chung; câu có số chấm bằng **Exact/Numeric Match khách quan** (không qua LLM-judge), câu mở chấm bằng LLM-as-judge hai chế độ STRICT/RELAXED, kèm faithfulness (định nghĩa trên).

Lưu ý về trình chấm. Ở bảng 101 câu này (harness eval-chatbot.ts), mô hình *sinh* và mô hình *chấm* cùng là deepseek-chat, nên các con số correctness do LLM chấm có nguy cơ **self-preference bias** [19][23]. Vì vậy chúng tôi đẩy chỉ số **Exact/Numeric Match khách quan** lên làm bằng chứng *xương sống* (câu có số được chấm bằng so khớp số học, không qua LLM), còn correctness-do-LLM-chấm đóng vai trò *bổ trợ có caveat*. Bộ **ba-môi-trường ở cuối mục này (Bảng V–VI)** khắc phục triệt để điểm yếu đó: chạy *cùng* bộ 101 câu nhưng **chấm hoàn toàn khách quan, không dùng LLM-judge** (câu mở đối chiếu dữ kiện theo quy tắc công khai), nên các con số chủ đạo không còn rủi ro self-preference và tái lập được 100%.

Bảng IV — Độ chính xác trước/sau RAG (chế độ STRICT), tách theo nhóm câu.

Cấu hình
Closed-book (không RAG)
Open-book Hybrid RAG
Δ

Bằng chứng xương sống — câu có số (Exact/Numeric Match khách quan). Với nhóm câu có đáp án số (số chỗ trống, toạ độ xe, số thiết bị ngoại tuyến), Exact-Match tăng từ ~3–11% (closed-book) lên **100%** (open-book) — đây là chỉ số *không qua LLM-judge* nên miễn nhiệm self-preference bias, và là minh chứng vững nhất cho luận điểm "RAG cứu câu trạng thái": closed-book gần như không thể nói đúng một con số runtime, còn open-book lấy đúng con số từ snapshot truy hồi.

Bổ trợ — correctness do LLM chấm (có caveat). RAG nâng độ chính xác tổng từ 5,0% lên 86,1% (+81,1 điểm phần trăm). Mức tăng lớn nhất ở nhóm **G2 trạng thái-IoT** (1,6% → 82,0%): closed-book gần như không trả lời được câu trạng thái thời gian thực vì thông tin đó không nằm trong tham số mô hình — phù hợp nhận định của các nghiên cứu về câu hỏi thay đổi nhanh [16][17]. Faithfulness 0,997 cho thấy câu trả lời open-book gần như hoàn toàn dựa trên ngữ cảnh được truy hồi. Cần nhắc lại đây là điểm do deepseek-chat tự chấm (xem caveat trên).

Lập luận thống kê. Tính khoảng tin cậy Wilson 95% cho hai tỉ lệ tổng (n=101) bằng công thức Wilson cho tỉ lệ nhị thức \$p\$ với \$z=1\$, \$96\%\$:
$$\frac{\hat{p} + \frac{1}{2n}}{1 + \frac{1}{4n}} \pm z \sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{1}{4n^2}}$$
 Với $\hat{p} = 0$, \$861\%\$, \$n=101\$: CI95% ≈ **[78,0% ; 91,5%]**. Với $\hat{p} = 0$, \$050\%\$, \$n=101\$: CI95% ≈ **[2,2% ; 11,1%]**. Hai khoảng *không giao nhau*, và khoảng cách giữa hai tỉ lệ (+81,1 điểm phần trăm) lớn hơn

hiều so với độ rộng của từng CI ($\approx 9\text{--}14$ điểm phần trăm), nên khác biệt không thể quy cho dao động ngẫu nhiên của cỡ mẫu này. Tuy vậy đây vẫn là bộ QA synthetic; **khảo sát người dùng thật là hướng tiếp theo bắt buộc**, song không phủ nhận đóng góp ở mức *systems* mà bài đã minh chứng định lượng.

Ablation TTL trên nhóm G2 (bằng chứng answer-level). So sánh open-book khi chỉ giữ snapshot *tươi* (lọc TTL) với khi để cả snapshot *cũ*: độ chính xác STRICT đạt **82,0%** (tươi) so với **75,4%** (cũ) — chênh **+6,6 điểm phần trăm**. Đây là *minh chứng định lượng ở mức câu trả lời* cho giá trị của lọc độ-cũ (bổ trợ cho bảo đảm an-toàn-theo-cấu-trúc ở tầng truy hồi, §IV-C): ngữ cảnh lỗi thời kéo tụt chất lượng trả lời, và lọc TTL ngay tại tầng truy hồi loại bỏ được nó. (Cỡ mẫu vừa, judge chưa hiệu chỉnh với người chấm — xem §F; đây là minh hoạ quy trình tái lập, không phải benchmark diện rộng.)

So sánh ba môi trường (none / MCP / MCP+RAG), hai mô hình và chi phí token. Để định vị Hybrid RAG bên cạnh hướng *gọi công cụ* (MCP/tool-calling), chúng tôi chạy **toàn bộ bộ 101 câu** (40 tình G1 + 61 trạng thái G2) trên **ba môi trường** — none (chỉ mô hình), mcp (mô hình + công cụ), mcp+rag (công cụ + Hybrid RAG) — với **hai mô hình DeepSeek-V3.2**: deepseek-chat (non-thinking) và deepseek-reasoner (có chuỗi suy luận). Công cụ do LLM tự gọi nhưng thực thi trên CSDL kịch bản (cùng nguồn đáp án vàng), embedding embeddinggemma 768-d, temperature 0. **Chăm điểm hoàn toàn khách quan, tái lập 100%**: câu có số dùng Exact/Numeric Match số học; câu mở chấm tự động bằng *đối chiếu dữ kiện cốt lõi của đáp án vàng* (key-fact recall + nhận diện từ chối) theo quy tắc công khai — **không dùng LLM-as-judge**, nhờ đó loại bỏ hoàn toàn nguy cơ self-preference/self-enhancement bias [19][23] vốn ảnh hưởng các thước đo dùng giám khảo-LLM. Bộ độ đo tham chiếu các khung uy tín: RAGAS [18] (sinh đáp án/RAG), BFCL [20] (tool-calling), τ -bench [21] (tác tử); accuracy kèm khoảng tin cậy Wilson 95% [22].

Bảng V — Ba môi trường $\times$ hai mô hình DeepSeek-V3.2 (n=101): độ chính xác (Wilson 95% CI), component-acc và token.

Mô hình	
chat	
chat	
chat	
reasoner	
reasoner	
reasoner	

Bảng VI — Độ đo tool-calling (phong cách BFCL [20]) trên hai môi trường có công cụ.

Mô hình
chat
chat
reasoner
reasoner

Độc kết quả. (1) *none* gần như vô dụng cho câu trạng thái ($G2 \approx 1,6\%$ ở cả hai mô hình): thông tin runtime không nằm trong tham số mô hình. (2) *MCP cứu nhóm trạng thái* ($G2$ lên 93,4%/88,5%) nhờ gọi đúng công cụ $\rightarrow$ đúng thẻ (tool-selection 100%, hallucinated-tool 0% — mô hình không bịa hàm ngoài schema), **nhưng kéo tụt tri thức tĩnh G1** (20% $\rightarrow$ 10%): khi có công cụ, mô hình cố định tuyến cả câu tri thức tĩnh sang một tool dữ liệu không phù hợp (không có tool tri thức), trả lời kém hơn cả khi không có tool — đúng **khoảng trống #2 ở §I** (tool-calling đẩy gánh nặng *định tuyến* sai sang LLM). (3) *MCP+RAG bù cả hai* (Tổng 100%/98%, $G1$ về 100%) nhờ Hybrid RAG cấp cả tri thức tĩnh lẫn ngữ cảnh trạng thái dạng ngôn ngữ. Hai khoảng Wilson của none và mcp+rag (chat: [5–16] so với [96–100]) **không giao nhau**, nên khác biệt không thể quy cho dao động ngẫu nhiên của cỡ mẫu.

Vì sao tool-call rate giảm ở MCP+RAG. Ở mcp+rag, tool-call rate tụt (chat 59,4% $\rightarrow$ 21,8%; reasoner 61,4% $\rightarrow$ 47,5%), kéo tool-selection acc giảm theo: vì ngữ cảnh Hybrid RAG **đã chứa sẵn IoT Snapshot** nên mô hình thường trả lời trực tiếp từ ngữ cảnh thay vì phát lời gọi công cụ — trong khi *Accuracy vẫn $\sim 100\%$* . Đây chính là minh chứng cho luận điểm cốt lõi: IoT Snapshot Documents giúp hệ thống **không phụ thuộc việc LLM định tuyến công cụ** cho câu trạng thái — vốn là điểm dễ sai của hướng thuần-MCP (chính nghịch lý $G1$ ở trên).

chat so với reasoner. Mô hình *non-thinking* (chat) **không thua** mô hình có chuỗi suy luận (reasoner): ở mcp+rag, chat đạt 100% so với 98,0% và **tốn ít token hơn** (1 871 so với 2 422 token/câu). Với tác vụ tra cứu/gọi-công-cụ trên bãi đỗ,

chuỗi suy luận dài không tăng độ chính xác mà tăng chi phí — gợi ý ưu tiên mô hình nhẹ cho triển khai. (n=101 đủ để CI thu hẹp, song vẫn là bộ QA synthetic; khảo sát người dùng thật là hướng tiếp theo.)

E. Độ trễ và đánh giá định vị

Độ trễ truy hồi. Trên corpus 458 đoạn (15 tỉnh + 443 snapshot tích lũy): BM25 thuần p50 ≈ 1,4 ms; chi-vector ≈ 211 ms; Hybrid không/có lọc TTL p50 ≈ 219/229 ms (p95 ≈ 297/1185 ms). Độ trễ bị chi phối bởi lời gọi sinh embedding truy vấn (~100 ms/lần do chạy embeddinggemma trên CPU) và kích thước corpus trong FULL OUTER JOIN. Trong vận hành, job dọn TTL giữ số snapshot thấp nên p95 ổn định; dịch vụ embedding đám mây dự kiến giảm ~một nửa chi phí. Độ trễ đầu-cuối (gồm LLM) là hướng đo tiếp theo.

Đánh giá định vị. UWB chỉ là nguồn dữ liệu; ta cung cấp harness tái lập (apps/iot-server/scripts/eval-positioning.ts, dựa trên evaluation.util.ts) tính RMSE/MAE/CEP/p95/Max theo điều kiện LOS·NLOS × giai đoạn raw·filtered, đưa dữ liệu qua đúng pipeline thật (trilateration + One-Euro). **Hệ thống hiện chưa có dữ liệu đo thực địa**; bảng dưới trình bày độ chính xác kỳ vọng theo tài liệu để biện luận, **không** phải kết quả của nghiên cứu này.

Bảng VII — Độ chính xác định vị: kỳ vọng theo tài liệu (KHÔNG phải kết quả của nghiên cứu này) và kết quả đo.

	Đ

F. Tính tái lập

Toàn bộ thí nghiệm chạy qua đúng mã sản xuất, không có nhánh đánh giá riêng. Truy hồi gọi trực tiếp hybridSearch(); ablation TTL/k là tham số của cùng hàm đó. Các harness độc lập tái tạo các bảng: eval-retrieval.ts (Bảng II–III), eval-chatbot.ts (Bảng IV), eval-mcp-rag.ts (Bảng V–VI) và eval-positioning.ts (Bảng VII). Cấu hình cố định để tái lập: embedding ``embeddinggemma`` 768 chiều chạy cục bộ (Ollama, không API đám mây), mô hình sinh ``deepseek-chat`/`deepseek-reasoner`` (DeepSeek-V3.2) với **temperature = 0**, RRF **k = 60**, TTL **2 giờ** (alert 24 giờ), corpus và bộ QA synthetic sinh từ kịch bản có seed cố định nên cùng đầu vào cho cùng kết quả. **Việc chấm câu mở ở Bảng V–VI không dùng LLM-judge mà theo quy tắc đối chiếu dữ kiện công khai (`grade-open.cjs`)**, nên bất kỳ ai cũng tái lập đúng từng điểm 0/1 từ judge-queue.json. Kiểm tra giao thức tool → component (8/8 schema hợp lệ, 0% thiếu renderer) chạy qua eval-component.ts. Mã nguồn, lược đồ CSDL, bộ QA, bốn harness và toàn bộ verdict/metrics được công bố cùng bài báo.

G. Giới hạn

- **Chưa đo thực địa:** chưa có dữ liệu định vị thật; harness mới chạy trên dữ liệu synthetic. Các chỉ số RMSE/CEP để trống chờ phần cứng và mặt bằng thật. - **Phụ thuộc hạn ngạch nhúng:** snapshot mỗi 5 phút để giữ dưới hạn ngạch; do đó trạng thái có độ trễ cập nhật tối đa ~5 phút. - **Fallback zero-vector:** khi thiếu khóa API nhúng hợp lệ, embed() trả vector-không, **vô hiệu hóa nhánh vector** — hệ thống lúc đó chỉ còn BM25. Đây là giới hạn cấu hình cần nêu rõ khi tái lập. - **Bộ QA synthetic:** đánh giá truy hồi/chatbot dựa trên câu hỏi sinh có kiểm soát, chưa phải truy vấn người dùng thật; cần khảo sát người dùng để khẳng định tính tổng quát. - **Thiên lệch của trình chấm:** ở Bảng IV (101 câu, harness eval-chatbot.ts), mô hình sinh và mô hình chấm cùng là deepseek-chat nên các con số *do-LLM-chấm* có nguy cơ *self-preference bias* [19][23]; vì vậy ở bảng đó ta đẩy Exact/Numeric Match khách quan lên làm xương sống. **Bộ ba-môi-trường (Bảng V–VI) đã loại hẳn rủi ro này:** toàn bộ câu mở chấm tự động bằng quy tắc đối chiếu dữ kiện công khai (không LLM-judge), nên không còn self-preference bias và tái lập 100%. Hạn chế còn lại: bộ QA vẫn là synthetic, chưa hiệu chỉnh với người chấm; khảo sát người dùng thật và đo *pass^k* (chạy lặp k lần) [21] là hướng tiếp theo.

V. KẾT LUẬN

Bài báo đề xuất **IoT Snapshot Documents** — một mẫu kiến trúc biến trạng thái IoT động thành tài liệu có TTL nằm cùng chỉ mục với tài liệu tĩnh, hòa trộn trong một câu truy vấn SQL lai (BM25 + pgvector + RRF k=60) với lọc độ-cũ tại tầng truy hồi — cho phép một trợ lý hội thoại trả lời thống nhất câu hỏi tri thức tĩnh lẫn câu hỏi trạng thái thời gian thực mà không phụ thuộc LLM định tuyến công cụ và không rò rỉ ngữ cảnh lỗi thời. Hệ thống được hiện thực end-to-end trên bãi đồ AIoT thực và kèm harness đánh giá tái lập. Hướng phát triển: (i) đo RMSE/CEP định vị thực địa để hoàn thiện §IV-E; (ii) chạy đầy đủ giao thức đánh giá truy hồi với bộ QA mở rộng và khảo sát người dùng thật; (iii) đo *pass^k* (chạy lặp k lần/câu) [21] cho nhóm trạng thái để định lượng tính ổn định của tác tử, và hiệu chỉnh trình chấm tự động với người chấm trên một mẫu kiểm; (iv) mở rộng các loại snapshot (sự kiện đỗ sai, dòng người-xe) và nghiên cứu TTL thích nghi theo tốc độ biến đổi của từng loại trạng thái.

VI. TÀI LIỆU THAM KHẢO

- [1] IEEE, "IEEE Std 802.15.4z-2020 — IEEE Standard for Low-Rate Wireless Networks—Amendment 1: Enhanced Ultra Wideband (UWB) Physical Layers (PHYs) and Associated Ranging Techniques". IEEE, 2020. [Online]. Available: <https://ieeexplore.ieee.org/document/9179124/>
- [2] G. Casiez, N. Roussel, and D. Vogel, "1€ Filter: A Simple Speed-Based Low-Pass Filter for Noisy Input in Interactive Systems," in *Proc. SIGCHI Conf. Human Factors in Computing Systems (CHI '12)*, Austin, TX, USA, 2012, pp. 2527–2530.
- [3] M. F. R. Al-Okby, S. Junginger, T. Roddelkopf, and K. Thuro, "UWB-Based Real-Time Indoor Positioning Systems: A Comprehensive Review," *Applied Sciences*, vol. 14, no. 23, art. 11005, 2024. [Online]. Available: <https://www.mdpi.com/2076-3417/14/23/11005>
- [4] H. Yang, Y. Wang, S. Xu, J. Bi, H. Jia, and C. K. Seow, "Ultra-Wideband Ranging Error Mitigation with Novel Channel Impulse Response Feature Parameters and Two-Step Non-Line-of-Sight Identification," *Sensors*, vol. 24, no. 5, art. 1703, 2024. [Online]. Available: <https://www.mdpi.com/1424-8220/24/5/1703>
- [5] F. Wang, H. Tang, and J. Chen, "Survey on NLOS Identification and Error Mitigation for UWB Indoor Positioning," *Electronics*, vol. 12, no. 7, art. 1678, 2023. [Online]. Available: <https://www.mdpi.com/2079-9292/12/7/1678>
- [6] S. Robertson and H. Zaragoza, "The Probabilistic Relevance Framework: BM25 and Beyond," *Foundations and Trends in Information Retrieval*, vol. 3, no. 4, pp. 333–389, 2009.
- [7] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, "Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods," in *Proc. 32nd Int. ACM SIGIR Conf. Research and Development in Information Retrieval (SIGIR '09)*, Boston, MA, USA, 2009, pp. 758–759.
- [8] P. Lewis *et al.*, "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020, pp. 9459–9474.
- [9] V. Karpukhin *et al.*, "Dense Passage Retrieval for Open-Domain Question Answering," in *Proc. 2020 Conf. Empirical Methods in Natural Language Processing (EMNLP)*, 2020, pp. 6769–6781.
- [10] Y. Dong, Y. L. Aung, S. Chattopadhyay, and J. Zhou, "ChatIoT: Large Language Model-based Security Assistant for Internet of Things with Retrieval-Augmented Generation," arXiv:2502.09896, 2025. [Online]. Available: <https://arxiv.org/abs/2502.09896>
- [11] T. An, Y. Zhou, H. Zou, and J. Yang, "IoT-LLM: A Framework for Enhancing Large Language Model Reasoning from Real-World Sensor Data," arXiv:2410.02429, 2024. [Online]. Available: <https://arxiv.org/abs/2410.02429>
- [12] M. Arazzi, M. Marconi Sciarroni, A. Nocera, and E. Storti, "RAG-IoE: IoT Context-Aware Information Retrieval with Large Language Models in Industry 5.0," *ACM Transactions on Internet of Things*, vol. 6, no. 4, art. 23, pp. 1–31, Nov. 2025. [Online]. Available: <https://dl.acm.org/doi/10.1145/3762669>
- [13] M. R. Alam, S. Saha, M. B. Bostami, M. S. Islam, M. S. Aadeeb, and A. K. M. M. Islam, "A Survey on IoT Driven Smart Parking Management System: Approaches, Limitations and Future Research Agenda," *IEEE Access*, vol. 11, pp. 119523–119543, 2023.
- [14] V. Paidi, H. Fleyeh, J. Håkansson, and R. G. Nyberg, "Smart Parking Sensors, Technologies and Applications for Open Parking Lots: A Review," *IET Intelligent Transport Systems*, vol. 12, no. 8, pp. 735–741, 2018.
- [15] OASIS, *MQTT Version 5.0 — OASIS Standard*, A. Banks, E. Briggs, K. Borgendale, R. Gupta (eds.), Mar. 7, 2019. [Online]. Available: <https://docs.oasis-open.org/mqtt/mqtt/v5.0/os/mqtt-v5.0-os.html>
- [16] T. Vu, M. Iyyer, X. Wang, N. Constant, J. Wei, J. Wei, C. Tar, Y.-H. Sung, D. Zhou, Q. Le, and T. Luong, "FreshLLMs: Refreshing Large Language Models with Search Engine Augmentation," arXiv:2310.03214, 2023. [Online]. Available: <https://arxiv.org/abs/2310.03214>
- [17] J. Kasai, K. Sakaguchi, Y. Takahashi, R. Le Bras, A. Asai, X. Yu, D. Radev, N. A. Smith, Y. Choi, and K. Inui, "RealTime QA: What's the Answer Right Now?," in *Advances in Neural Information Processing Systems (NeurIPS) — Datasets and Benchmarks Track*, vol. 36, 2023. [Online]. Available: <https://arxiv.org/abs/2207.13332>
- [18] S. Es, J. James, L. Espinosa-Anke, and S. Schockaert, "RAGAs: Automated Evaluation of Retrieval Augmented Generation," in *Proc. 18th Conf. European Chapter Assoc. Comput. Linguistics (EACL): System Demonstrations*, 2024, pp. 150–158. [Online]. Available: <https://aclanthology.org/2024.eacl-demo.16/>
- [19] L. Zheng, W.-L. Chiang, Y. Sheng, S. Zhuang, Z. Wu, Y. Zhuang, Z. Lin, Z. Li, D. Li, E. P. Xing, H. Zhang, J. E. Gonzalez, and I. Stoica, "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena," in *Advances in Neural Information Processing Systems (NeurIPS) — Datasets and Benchmarks Track*, 2023. [Online]. Available: <https://arxiv.org/abs/2306.05685>
- [20] S. G. Patil, H. Mao, F. Yan, C. C.-J. Ji, V. Suresh, I. Stoica, and J. E. Gonzalez, "The Berkeley Function Calling Leaderboard (BFCL): From Tool Use to Agentic Evaluation of Large Language Models," in *Proc. 42nd Int. Conf. Machine Learning (ICML)*, PMLR, vol. 267, 2025. [Online]. Available: <https://proceedings.mlr.press/v267/patil25a.html>
- [21] S. Yao, N. Shinn, P. Razavi, and K. Narasimhan, "t-bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains," in *Proc. Int. Conf. Learning Representations (ICLR)*, 2025. arXiv:2406.12045. [Online]. Available: <https://arxiv.org/abs/2406.12045>
- [22] L. D. Brown, T. T. Cai, and A. DasGupta, "Interval Estimation for a Binomial Proportion," *Statistical Science*, vol. 16, no. 2, pp. 101–133, 2001, doi: 10.1214/ss/1009213286.
- [23] W. Wataoka, T. Takahashi, and R. Ri, "Self-Preference Bias in LLM-as-a-Judge," arXiv:2410.21819, 2024. [Online]. Available: <https://arxiv.org/abs/2410.21819>